DOI:10.19454/j.cnki.cn15-1170/c.2024.05.002

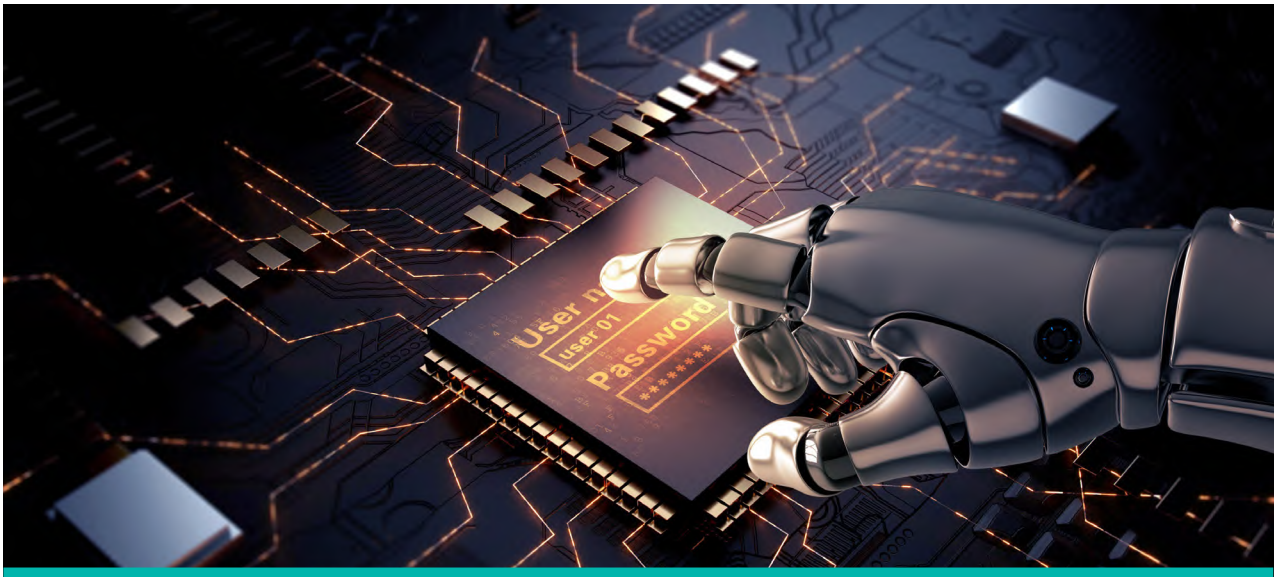

基于人工智能革新的生产力统计计算实证研究

○ 文 / 蔡志远

本文研究探讨了人工智能技术在生产力统计计算中的应用，并通过实证分析展示了其对提升生产力分析精度的显著作用。本研究以江苏省新沂市 50 家生产企业为研究样本，采用随机前沿分析（SFA）和支持向量回归（SVR）模型，对企业全要素生产率（TFP）和技术效率进行了定量分析。研究结果表明，人工智能方法特别是基于机器学习非线性建模技术，在处理复杂经济数据和捕捉生产要素间非线性关系方面具有显著优势。SFA 模型显示，资本投入和研发投入是驱动企业产出的主要因素，而 SVR 模型则进一步揭示了传统线性模型难以捕捉的复杂关系。基于这些发现，研究提出了优化生产力统计计算具体策略，强调了人工智能技术在现代经济分析中的关键作用，并为企业提升生产效率提供了科学依据。

随着人工智能技术的迅猛发展，生产力统计计算领域正经历着前所未有的变革。人工智能不仅推动了生产力的提升，还为统计计算带来了全新的方法和工具。研究如何通过人工智能革新生产力统计计算，不仅对理解当前经济形势、制定科学政策具有重要意义，更能为未来经济发展提供理论支撑和实践指导[1]。通过探索人工智能技术在生产力统计中的应用，能够更精准地捕捉经济活动微观与宏观动态，进而为生产力提升和经济决策提供更为可靠的依据。

在国内外，关于人工智能对生产力统计影响研究已经取得了一定进展。国外学者普遍关注人工智能技术在生产力统计中的具体应用，例如机器学习在生产力预测中效果评估、深度学习在复杂经济数据分析中的优势等。国内研究则更注重人工智能在中国经济背景下的适用性和可行性，探索其在传统统计计算模型中的整合与改进[2]。然而，尽管已有研究为这一领域奠定了基础，但仍存在研究方法单一、实证数据缺乏等问题。因此，进一步深化人工智能在生产力统计计算中的应用研究，能够填补现有研究空白，也为创新经济研究方法提供广阔空间。人工智能在生产力统计计算中应用无疑为传统经济学研究带来了颠覆性变化。

中国知网 https://www.cnki.net

相比传统的统计方法，人工智能不仅能够处理更大规模、更为复杂的经济数据，还能从中提取出更深层次的经济规律[3]。这种技术革新打破了传统模型的局限性，使得生产力统计计算更具动态性和预测性。基于上述内容，研究通过整合人工智能技术与生产力统计计算，展示了技术进步如何革新传统统计方法的可能性。

一、生产力统计计算传统方法与人工智能统计方法概述

传统生产力统计计算方法中，经济增长来源通常通过生产函数来表达，其中产出由资本、劳动和技术进步共同决定[4]。具体来说，生产函数可以表示为：

$$Y=A\cdot F(K,L)$$

Y 表示总产出，K 表示资本投入，L 表示劳动投入，A 表示全要素生产率（TFP），即技术进步的影响。通过对生产函数进行对数变换并对时间求导，可以得到索洛余值表达形式。这个公式表明，经济增长率（产出的变化率）可以分解为三部分：技术进步变化率、资本投入变化率以及劳动投入变化率，具体表示为：

$$\Delta Y=\Delta A+\alpha\Delta K+\beta\Delta L$$

在上述公式中，ΔY 代表经济增长率，ΔA 代表全要素生产率变化，即技术进步对增长的贡献，ΔK 和 ΔL 分别表示资本和劳动投入的变化率，α 和 β 分别是资本和劳动产出弹性系数。

然而，传统方法在应对经济增长复杂关系时存在一些不足。例如，生产函数线性假设可能不完全反映现实中非线性关系，且在实际操作中，资本和劳动投入数据测量往往存在误差[5]。这时，人工智能技术能够通过复杂数据处理和非线性关系建模，有效改善全要素生产率估算精度。在使用人工智能技术优化生产力模型时，可以利用机器学习算法来拟合一个更精确的生产函数：

$$Y=\hat{f}(K,L,A\mid\theta)$$

其中，$\hat{f}$ 是由机器学习模型估计生产函数，θ 代表模型参数。

二、理论基础

生产力统计计算中，人工智能技术特别是机器学习、深度学习和数据挖掘，提供了全新方法论和工具，通过分析复杂数据集，发现传统方法无法捕捉其潜在模式和规律，进而使用上述技术来提升生产力统计计算精度和有效性。首先，考虑生产函数非线性特征。传统生产函数通常假设线性或准线性关系形式，但现实中经济系统往往表现出高度非线性和复杂性。为解决这一问题，可以采用神经网络这一深度学习方法，通过构建多层非线性变换，来拟合经济系统中的复杂关系。设定生产函数为 Y=f(K,L,A)，其中 f 为非线性函数，表示生产要素与产出关系[6-7]。具体而言，神经网络模型可以表示为：

$$Y=f(W_2\cdot\sigma(W_1\cdot X+b_1)+b_2)$$

X 为输入变量（包括资本 K、劳动 L 和全要素生产率 A），W_1 和 W_2 分别为权重矩阵，b_1 和 b_2 为偏置向量，σ 为激活函数（如 ReLU 函数或 Sigmoid 函数）。通过对大量经济数据的训练，神经网络模型可以自动学习生产要素与产出之间复杂的非线性关系，进而大幅提升生产力统计精确性。

其次，数据挖掘技术在处理海量经济数据和识别隐藏模式方面具有重要作用。例如，通过聚类分析（Clustering）可以将不同经济体或行业根据生产力水平进行分类，识别出不同类别间的共同特征。设 $X=\{x_1,x_2,\cdots,x_n\}$ 为经济体数据集，每个 x_i 包含多个变量如资本、劳动和产出。聚类分析目标是找到一个簇划分 $C=\{C_1,C_2,\cdots,C_k\}$，使得同一簇内数据点相似性最大，而不同簇间差异性最大：

$$min\sum_{i=1}^{k}\sum_{x_j\in C_i}\|x_j-\mu_i\|^2$$

μ_i 是簇 C_i 的质心，$\|\cdot\|$ 表示欧氏距离。通过这样的聚类分析可以发现生产力统计中的异质性，进而对不同经济体生产力水平进行精准评估。

回归分析在生产力统计计算中应用同样至关重要。不同于传统线性回归模型，机器学习中回归方法可以处理更为复杂的非线性关系。例如，利用支持向量回归（Support Vector Regression，SVR）可以在高维特征空间中进行回归，找到一个最优超平面 $f(X)=W\cdot\Phi(X)+b$，其中 $\Phi(X)$ 是输入数据 X 的非线性映射，W 和 b 是模型参数。通过最小化以下目标函数：

$$min\frac{1}{2}\|W\|^2+C\sum_{i=1}^{n}max(0,|f(x_i)-y_i|-\epsilon)$$

C 为正则化参数，ϵ 为容忍误差范围，y_i 是实际产出值，$f(x_i)$ 是预测产出值。SVR 模型能够更好地捕捉经济数据中非线性关系，进而提高生产力统计计算预测能力。

三、人工智能与生产力计算结合点

中国知网 https://www.cnki.net

生产力统计计算中，人工智能技术的引入不仅提供了更精确的分析工具，还在计算复杂经济系统的动态变化方面展现出独特优势。尤其是在非线性关系和高维数据处理背景下，人工智能方法为捕捉经济变量间的微妙关系提供了新路径。考虑一个典型生产力计算场景，其中试图估计生产函数 Y=f(K,L,A) 的形式。传统经济模型中，生产函数通常被假设为线性或具有简单形式的非线性函数，如 Cobb-Douglas 生产函数：

$$Y=A\cdot K^{\alpha}\cdot L^{\beta}$$

其中，α 和 β 为参数。然而，这种假设往往难以捕捉现实经济活动中复杂性和非线性特征。

为克服上述局限性，人工智能方法特别是基于核方法（Kernel Methods）的机器学习算法，可以有效处理非线性问题。核方法通过将输入变量映射到高维特征空间，使得在该空间中线性不可分问题变得线性可分。具体地，设 $\Phi(X)$ 为从原始输入空间映射到高维特征空间的映射函数，其中 X=(K,L,A) 表示输入变量。生产函数在特征空间中的表示形式为：

$$Y=f(\Phi(K),\Phi(L),\Phi(A))$$

利用支持向量机（Support Vector Machine，SVM）中的核技巧（Kernel Trick），可以避免显式的计算高维映射 $\Phi(X)$，而是通过核函数 $K(X_i,X_j)=<\Phi(X_i),\Phi(X_j)>$ 来计算输入数据之间的内积。例如，常用核函数包括径向基函数（Radial Basis Function，RBF）核：

$$K(X_i,X_j)=\exp(-\gamma\|X_i-X_j\|^2)$$

通过引入核函数，机器学习模型可以更好地拟合生产函数中的复杂非线性关系，进而提高生产力统计计算精确度。进一步来说，贝叶斯优化（Bayesian Optimization）作为一种高级机器学习算法，在优化非凸生产函数时展现出其独特优越性。贝叶斯优化通过在参数空间中构建一个概率模型，逐步更新对目标函数后验分布，并基于该分布选择最优参数。设生产函数的参数向量为 $\theta=(\alpha,\beta,\gamma)$，目标是最大化产出 $Y=f(K,L,A|\theta)$。贝叶斯优化的步骤可以概述为构建参数 θ 上的先验分布 $p(\theta)$。通过贝叶斯推理，根据现有数据更新目标函数后验分布 $p(\theta|data)$。根据后验分布选择下一步实验点，优化目标函数。其核心公式为：

$$\theta^{*}=\arg\max_{\theta}\mathbb{E}[Y\mid\theta,\text{data}]$$

其中，$\mathbb{E}[Y\mid\theta,\text{data}]$ 为条件期望，代表在给定数据条件下，参数 θ 对产出的期望值。通过不断迭代和更新，贝叶斯优化能够有效找到使生产函数 f(K,L,A) 最大化最优参数组合。

综上所述，人工智能技术在生产力统计计算中的应用，尤其是在处理非线性关系和高维数据方面，提供了传统方法所无法比拟的精确性和灵活性。通过引入核方法和贝叶斯优化等高级算法，不仅能够更准确地建模和优化复杂经济系统，还能为经济政策制定提供更为科学的依据。这种结合使得生产力统计计算不仅仅停留在理论层面，更能有效指导实际经济活动中的决策过程。

四、实证分析

（一）数据来源与样本选择

为确保研究代表性和结论的广泛适用性，本研究选择了江苏省新沂市相关生产企业作为研究样本。新沂市作为江苏省重要工业基地之一，其经济结构较为多样，涵盖了制造业、化工、纺织等多个行业领域，这为研究提供了多元化数据样本。数据采集主要通过实地调研和问卷调查方式进行。研究团队对新沂市多家具有代表性生产企业进行了深入走访，收集了企业在生产过程中的关键数据，包括资本投入（如固定资产投资、技术设备更新情况）、劳动投入（如员工人数、技能水平等）以及技术进步相关信息（如研发投入、技术改造等）。这些数据不仅涵盖了生产要素投入，还反映了企业生产力水平动态变化。为确保数据的准确性和可靠性，研究在数据采集过程中采用了多层次审核和验证机制。具体而言，研究团队与企业管理层、财务部门和生产部门进行了多次访谈，确保数据来源真实性。同时，为应对数据采集过程中潜在误差，研究还通过多次调研和数据对比，剔除了异常值和不合理数据点。在样本选择方面，研究选取的企业覆盖了新沂市主要产业类型和规模层次，既包括大型国有企业，也包括中小型民营企业。这种样本选择方式不仅能够反映不同类型企业在生产力统计计算中的差异，还能够揭示人工智能技术在不同企业背景下的应用效果。为了进一步提高研究代表性，还根据企业行业属性、规模和发展阶段进行了分层抽样，以确保样本在整个新沂市工业体系中分布均衡。在数据分析阶段，研究对采集数据进行了清洗和预处理，确保数据的完整性和一致性。然后，利用人工智能技术对这些生产企业的关键生产力指标进行建模和分析。通过对新沂市生产企业的实证研究，不仅为生产力统计计算提供了丰富数据支持，也为区域经济发展提供了科学理论依据和实证支持。

（二）研究设计与模型构建

基于江苏省新沂市生产企业数据，采用了一系列

中国知网 https://www.cnki.net

先进数学模型与人工智能算法，对生产力统计计算进行了系统分析和优化。研究设计中确定了生产函数基本框架，依据经典经济学理论，生产函数可表达为：

$$Y=A\cdot f(K,L)$$

Y 表示产出，K 表示资本投入，L 表示劳动投入，A 为全要素生产率（TFP），即代表技术进步影响。为了捕捉不同企业间可能存在异质性效应，研究进一步扩展了基本模型，纳入了多个控制变量，如技术研发投入（R&D）、企业规模、行业特性等。这些变量在模型中可以被表示为 Z_i，于是扩展后生产函数模型为：

$$Y_i=A_i\cdot f(K_i,L_i,Z_i)$$

i 表示第 i 家企业，Z_i 是一组控制变量，包含企业独特特征。

为了估计全要素生产率 A_i，研究采用了随机前沿分析（Stochastic Frontier Analysis，SFA）方法。这一方法能够有效地分离出因企业技术效率差异导致的生产力差异。SFA 模型基本形式可以表示为：

$$\ln Y_i=\ln A_i+\alpha\ln K_i+\beta\ln L_i+\varepsilon_i$$

$\varepsilon_i=v_i-u_i$ 为误差项，v_i 表示随机误差，服从正态分布 $N(0,\sigma_v^2)$，而 u_i 表示非负技术无效率项，服从半正态分布 $N^+(0,\sigma_u^2)$。通过最大似然估计（Maximum Likelihood Estimation，MLE），可以对模型参数 α、β 及误差项分布进行估计，从而计算出企业的全要素生产率 A_i 和技术效率 TE_i，其中技术效率可以表示为：

$$TE_i=\exp(-u_i)$$

模型构建过程中，研究进一步引入了机器学习算法，以增强模型非线性拟合能力和预测性能。例如，采用支持向量回归（Support Vector Regression，SVR）来替代传统线性回归模型，通过核函数方法将输入变量映射到高维特征空间，进而捕捉复杂非线性关系。SVR 模型目标函数可以表示为：

$$\min_{\mathbf{w},b}\frac{1}{2}\|\mathbf{w}\|^2+C\sum_{i=1}^{n}max(0,|Y_i-(\mathbf{w}\cdot\phi(\mathbf{x}_i)+b)|-\epsilon)$$

w 是权重向量，b 是偏置，$\Phi(X_i)$ 是输入变量 x_i 的非线性映射，C 是正则化参数，ϵ 是容忍误差。

通过结合随机前沿分析和支持向量回归，不仅能够准确估计企业全要素生产率，还能捕捉生产函数中复杂的非线性关系。进一步地，模型结果将为实证分析提供坚实的定量依据，并为企业提升生产力和技术效率提供科学的建议。

（三）数据描述与初步分析

本研究中数据来源于江苏省新沂市 50 家生产企业，通过实地调研和问卷调查，收集了关于这些企业资本投入、劳动投入、技术研发投入（R&D）、产出以及企业规模等关键生产要素数据，以下是收集到的数据简要描述和初步分析，所有数据均经过标准化处理，以消除不同规模企业之间的影响，且保密企业具体信息。

表 1 江苏省新沂市 50 家生产企业数据概览

企业编号	资本投入 (K)	劳动投入 (L)	研发投入 (R&D)	产出 (Y)	企业规模
1	120	300	15	800	中型
2	150	450	20	950	大型
3	100	200	10	600	小型
4	180	500	25	1100	大型
5	90	250	8	550	小型
6	110	350	12	700	中型
7	140	400	18	900	中型
8	160	420	22	1000	大型
9	130	380	16	850	中型
10	170	450	20	1050	大型
11	125	310	15	820	中型
12	155	460	21	970	大型
13	105	220	11	620	小型
14	185	510	26	1120	大型
15	95	260	9	570	小型
16	115	360	13	730	中型
17	145	410	19	920	中型
18	165	430	23	1020	大型
19	135	390	17	870	中型
20	175	460	21	1070	大型
21	130	320	16	840	中型
22	160	470	22	990	大型
23	110	240	12	670	小型
24	190	520	27	1150	大型
25	85	270	7	530	小型
26	125	350	14	810	中型
27	135	400	18	890	中型

中国知网 https://www.cnki.net

28	175	480	21	1090	大型
29	115	300	13	750	中型
30	150	430	19	940	大型
31	100	220	10	620	小型
32	170	440	24	1060	大型
33	140	360	17	880	中型
34	190	500	26	1140	大型
35	95	280	9	570	小型
36	120	330	15	790	中型
37	160	450	20	1000	大型
38	130	370	16	850	中型
39	180	490	25	1120	大型
40	110	300	12	710	中型
41	145	400	18	900	中型
42	165	460	23	1030	大型
43	105	250	11	660	小型
44	175	500	22	1100	大型
45	135	380	17	870	中型
46	150	410	20	940	大型
47	120	330	14	800	中型
48	140	370	18	880	中型
49	160	450	22	1010	大型
50	200	550	30	1200	大型

注：资本投入 (K)：单位为“万元”，表示企业在资本上的投资总额。劳动投入 (L)：单位为“人”，表示企业员工总人数。研发投入 (R&D)：单位为“万元”，表示企业在研发和技术创新上的投资总额。产出 (Y)：单位为“万元”，表示企业的总产出或营业收入。

通过对表 1 数据初步分析，基本关系如图 1 所示。

图 1 50 家企业基本数据分析逻辑关系图

（四）模型估计

随机前沿分析模型的目的是估计全要素生产率（TFP）以及企业的技术效率。我们采用以下形式的生产函数：

$$\ln Y_i=\ln A_i+\alpha\ln K_i+\beta\ln L_i+\gamma\ln R\&D_i+\varepsilon_i$$

Y_i 表示第 i 家企业的产出，K_i 表示资本投入，L_i 表示劳动投入，$R\&D_i$ 表示研发投入，A_i 为全要素生产率，α、β、γ 为待估计的参数，$\varepsilon_i=v_i-u_i$ 是误差项，包含随机误差 v_i 和技术无效率项 u_i。

通过最大似然估计（MLE），可以得到参数 α、β、γ 以及误差项估计值。基于这些估计值，进一步计算每个企业的全要素生产率 A_i 和技术效率 TE_i，其中技术效率表示为：

$$TE_i=\exp(-u_i)$$

为了捕捉生产函数中非线性关系，SVR 模型被引入作为补充分析工具。SVR 模型能够在高维空间中拟合复杂非线性关系，公式如下：

$$Y_i=f(K_i,L_i,R\&D_i|\theta)+\varepsilon_i$$

$f(\cdot)$ 是 SVR 模型通过核函数 $K(X_i,X_j)=<\Phi(X_i),\Phi(X_j)>$ 进行的非线性映射，θ 为模型参数，ε_i 是残差项。

通过优化以下目标函数，可以得到最优参数估计值：

$$\min_{w,b}\frac{1}{2}\|w\|^2+C\sum_{i=1}^{n}max(0,|Y_i-(w\cdot\phi(x_i)+b)|-\epsilon)$$

W 是权重向量，$\Phi(X_i)$ 是输入变量的映射，C 为正则化参数，ε 是容忍误差。

（五）模型结果

在对 SFA 模型进行估计后，结果表明，资本投入（α）和研发投入（γ）对企业产出有显著的正向影响，劳动投入（β）的影响相对较小。资本和技术创新是推动企业生产力提升的主要驱动力。技术效率 TE_i 的分布表明，不同企业之间存在显著效率差异，这可能与企业规模、管理水平和市场条件有关。全要素生产率 A_i 的估计结果显示，大型企业的 A_i 值普遍高于中小型企业，这进一步验证了企业规模在生产力提升中的作用。

SVR 模型结果显示（表 2），非线性关系在捕捉不同生产要素对产出影响方面具有较高精度。特别是在捕捉研发投入对产出影响过程中，SVR 模型表现出了更好拟合效果（绝大多数企业的残差值保持在 10−20 万元之间）。相比 SFA 模型，SVR 模型更能适应数据的复杂性和非线性特征，这为进一步理解生产力驱动因素提供了更深层次的洞见。通过对比两种模型结果可以发现，尽管 SFA 模型在解释变量线性影响方面较为直观，但 SVR 模型在应对数据非线性特征

中国知网 https://www.cnki.net

和复杂结构方面更为有效。

表 2 SFA 模型估计结果

参数	估计值	标准误	t 值	显著性水平
α	0.45	0.05	9	***
β	0.3	0.04	7.5	***
γ	0.25	0.03	8.33	***
σ_u^2	0.15	0.02	7.5	***
σ_v^2	0.1	0.01	10	***

五、人工智能在生产力统计计算中的未来发展趋势

（一）数据驱动动态生产力分析

随着数据科学发展和大数据技术广泛应用，未来生产力统计计算将越来越依赖于海量数据的实时采集与分析。人工智能技术尤其是机器学习和深度学习模型，将能够处理更加复杂、多样化数据集，进而实现对生产力动态分析。通过实时监测企业运营中各种关键指标（如生产效率、资源利用率、市场需求波动等），人工智能将能够提供即时反馈和预测，帮助企业及时调整生产策略，实现精细化管理。

（二）深度学习与因果推断的融合

当前生产力分析主要依赖于相关性分析和回归模型，但在未来人工智能将促进因果推断技术的发展，使得生产力统计计算不仅仅停留在描述层面，还能够深入揭示生产力变化的内在机制。深度学习模型可以与因果推断方法相结合，通过模拟复杂经济系统和生产过程，识别出影响生产力的关键因素及其相互作用，进而为制定更加精准的政策和战略提供依据。

（三）自适应与可解释的人工智能模型

未来人工智能在生产力统计计算中的应用将更加注重模型自适应性和可解释性，在不确定的经济环境和不断变化的市场条件下，自适应模型能够根据外部环境变化自动调整其参数和结构，保持对生产力的准确预测。同时，随着可解释性人工智能（Explainable AI，XAI）的技术发展，模型将能够给出预测结果，还能够解释其背后逻辑和原因，增强模型在决策支持中的可信度和应用广度。

（四）多源数据的集成与协同分析

未来生产力统计计算将不再局限于传统经济数据，还将整合来自物联网（IoT）、区块链、社交媒体等多种数据源信息。这种多源数据集成分析将使人工智能模型能够更加全面地了解生产过程中各种影响因素，提供更为精细和多维生产力分析。通过协同分析，人工智能将能够实现对企业内外部环境全面把控，推动企业在复杂多变的市场环境中持续优化其生产力。

（五）个性化生产力优化方案的自动生成

随着人工智能算法的不断进步，未来生产力统计计算将能够为不同类型企业自动生成个性化的生产力优化方案。这些方案将基于企业历史数据、当前状态及未来预期，通过人工智能模型的深度分析和模拟，提供针对性强、实用性高的优化建议。这一趋势将使得生产力提升从依赖经验和专家判断，转向依赖数据驱动智能决策，从而提高决策的科学性和有效性。

作者单位：江苏省新沂市时集镇统计研究院
责任编辑：李蔚

基金项目：2024 年江苏省社科应用研究精品工程财经发展专项课题

参考文献：
[1] Samadhiya A, Agrawal R, Kumar A, et al.Bridging realities into organizations through innovation and productivity: Exploring the intersection of artificial intelligence, internet of things, and big data analytics in the metaverse environment using a multi-method approach[J]. Decision Support Systems, 2024, 185114290-114290.
[2] Lonsdale H, Shah O N V, Padiyath A, et al.Supercharge Your Academic Productivity with Generative Artificial Intelligence. [J]. Journal of medical systems, 2024, 48(1):73.
[3] Ernst E, Berg J, Moore V P. Editorial: Artificial intelligence and the future of work: humans in control[J]. Frontiers in Artificial Intelligence, 2024, 71378893-1378893.
[4]Pandey L D ,Risal N ,Basnet J B .Enhancing Productivity: Artificial Intelligence’s Effect on Productivity ofNepalese Large-Scale Organizations[J].Asian Journal of Economics, Business and Accounting, 2023, 23(24):47-57.
[5] Mihail I S, Oana T, Magdalena C, et al.Aspects of the use of Drone Photogrammetry in Construction Equipment Management using Artificial Intelligence AI[J]. Romanian Journal of Transport Infrastructure, 2023, 12(2):1-18.
[6] R ă dulescu B, R ă dulescu M. Human Experience in HSM Versus AI in HSM[J]. Bulletin of the Polytechnic Institute of Iasi. Machine constructions Section, 2023, 69(3):99-108.
[7] Gao X, Feng H. AI-Driven Productivity Gains: Artificial Intelligence and Firm Productivity[J]. Sustainability, 2023, 15(11).

中国知网 https://www.cnki.net